现代信息检索

Modern Information Retrieval

第3讲 索引压缩

Index compression

*改编自”An introduction to Information retrieval”网上公开的课件，地址 http://nlp.stanford.edu/IR-book/

提纲

1. 上一讲回顾
2. 压缩
3. 词项统计量
4. 词典压缩
5. 倒排记录表压缩

提纲

基于块的排序索引构建算法BSBI

待合并的倒排记录表

Term id	Doc id
1	d1, d3
2	d1, d2, d4
3	d5
4	d1, d2, d3, d5

Term id	Doc id
1	d6, d7
2	d8, d9
5	d10
6	d8

合并后的倒排记录表

Term id	Doc id
1	d1, d3, d6, d7
2	d1, d2, d4, d8, d9
3	d10
4	d8
5	d5
6	d1, d2, d3, d5

合并过程基本不占用内存，但是需要维护一个全局词典

词典： 维护一张词项到整型词项ID的映射表

待合并的倒排记录表： 只包含整型ID，没有字符串

全局词典

term	term id	term	term id
brutus	1	with	4
caesar	2	julius	5
noble	3	killed	6

内存式单遍扫描索引构建算法SPIMI

- 关键思想 1：对每个块都产生一个独立的词典 - 不需要在块之间进行term-termID的映射
- 关键思想2：对倒排记录表不排序，按照他们出现的先后顺序排列
- 基础上述思想可以对每个块生成一个完整的倒排索引
- 这些独立的索引最后合并一个大索引

SPIMI-Invert算法

```
SPIMI-INVERT(token_stream)
 1  output_file ← NEWFILE()
 2  dictionary ← NEWHASH()
 3  while (free memory available)
 4  do token ← next(token_stream)
 5     if term(token) ∉ dictionary
 6        then postings_list ← ADDTODICTIONARY(dictionary, term(token))
 7        else postings_list ← GETPOSTINGSLIST(dictionary, term(token))
 8     if full(postings_list)
 9        then postings_list ← DOUBLEPOSTINGSLIST(dictionary, term(token))
10     ADDTOPOSTINGSLIST(postings_list, docID(token))
11  sorted_terms ← SORTTERMS(dictionary)
12  WRITEBLOCKTODISK(sorted_terms, dictionary, output_file)
13  return output_file
```

本讲内容

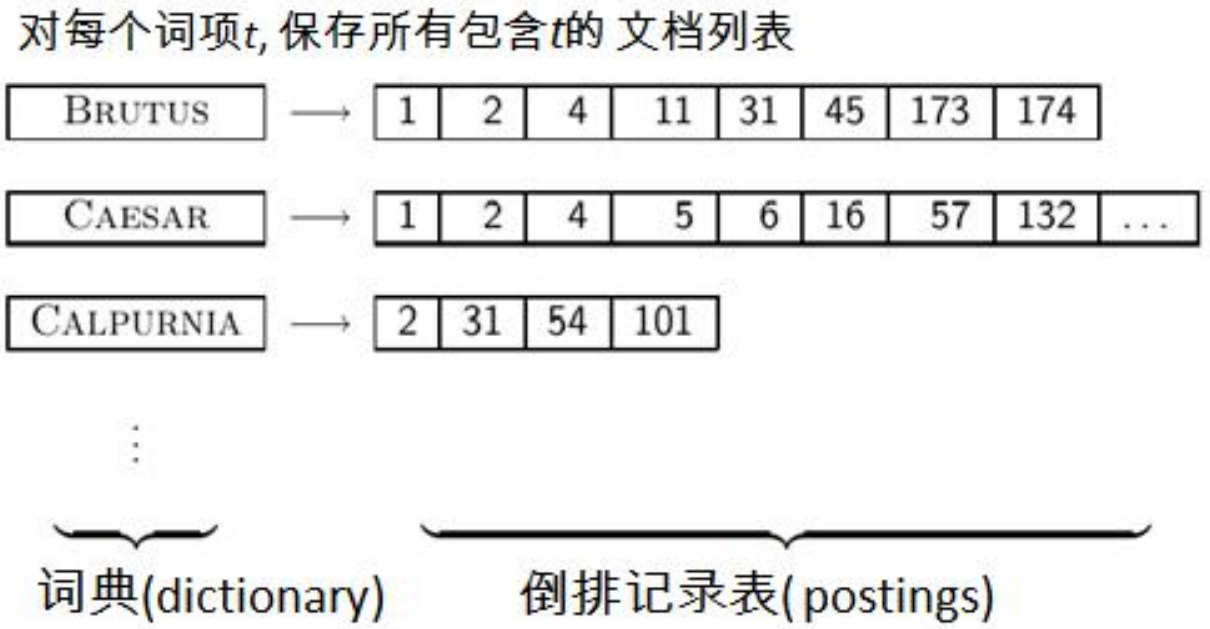

- 信息检索中进行压缩的动机
- 词项统计量：词项在整个文档集中如何分布？
- 倒排索引中词典部分如何压缩？
- 倒排索引中倒排记录表部分如何压缩？

提纲

什么是压缩？

- 将长编码串用短编码串来代替
  - 1111111111111111➔ 18个1

为什么要压缩? (一般意义上而言)

- 减少磁盘空间 (节省开销)
- 增加内存存储内容 (加快速度)
- 加快从磁盘到内存的数据传输速度 (同样加快速度)
  - [读压缩数据到内存+在内存中解压]比直接读入未压缩数据要快很多
  - 前提: 解压速度很快
- 本讲我们介绍的解压算法的速度都很快

为什么在IR中需要压缩?

- 占用更少的硬盘空间
  - 更经济，节省空间
- 将更多数据载入内存
  - 加快处理速度（内存中读写很快）
- 减少从磁盘读入内存的时间
  - 注意: 大型搜索引擎将相当比例的倒排记录表都放入内存
- IR中压缩的两个基本要求
  - （通常是）无损压缩
  - 随机访问 （ Random Access）
- 接下来，将介绍词典压缩和倒排记录表压缩的多种机制
  - 压缩的一个基本问题：对齐。即不同压缩单元之间的分界标识

有损(Lossy) vs. 无损(Lossless)压缩

- **有损压缩**: 丢弃一些信息
- 前面讲到的很多常用的预处理步骤可以看成是有损压缩:
  - 统一小写,去除停用词, Porter词干还原, 去掉数字

- **无损压缩**: 所有信息都保留
  - 索引压缩中通常都使用无损压缩

提纲

词典压缩和倒排记录表压缩

- 词典压缩中词典的大小即词汇表的大小是关键
  - 能否预测词典的大小？
- 倒排记录表压缩中词项的分布情况是关键
  - 能否对词项的分布进行估计？
- 引入词项统计量对上述进行估计，引出两个经验法则

对文档集建模： Reuters RCV1

N	文档数目	**800,000**
L	每篇文档的词条数目	**200**
M	词项数目(= 词类数目)	**400,000**
	每个词条的字节数 (含空格和标点)	**6**
	每个词条的字节数 (不含空格和标点)	**4.5**
	每个词项的字节数	**7.5**
T	无位置信息索引中的倒排记录数目	**100,000,000**

预处理的效果

	不同词项			无位置信息倒排记录			词　条①		
	数目	Δ%	T%	数目	Δ%	T%	数目	Δ%	T%
未过滤	484 494			109 971 179			197 879 290		
无数字	473 723	–2	–2	100 680 242	–8	–8	179 158 204	–9	–9
大小写转换	391 523	–17	–19	96 969 056	–3	–12	179 158 204	–0	–9
30个停用词	391 493	–0	–19	83 390 443	–14	–24	121 857 825	–31	–38
150个停用词	391 373	–0	–19	67 001 847	–30	–39	94 516 599	–47	–52
词干还原	322 383	–17	–33	63 812 300	–4	–42	94 516 599	–0	–52

Δ%：与上一步相比的变化百分比

T%：与未过滤相比的变化百分比

第一个问题：词汇表有多大(即词项数目)?

- 即有多少不同的单词数目?
  - 首先，能否假设这个数目存在一个上界?
  - 不能：对于长度为20的单词，有大约$70^{20} \approx 10^{37}$ 种可能的单词
- 实际上，词汇表大小会随着文档集的大小增长而增长!
- Heaps定律: $M = kT^b$
  - M 是词汇表大小, T 是文档集的大小(所有词条的个数，即所有文档大小之和)
- 参数k 和b 的一个经典取值是: $30 \leq k \leq 100$ 及 $b \approx 0.5$.
- Heaps定律在对数空间下是线性的
  - 这也是在对数空间下两者之间最简单的关系
  - 经验规律

Reuters RCV1上的Heaps定律

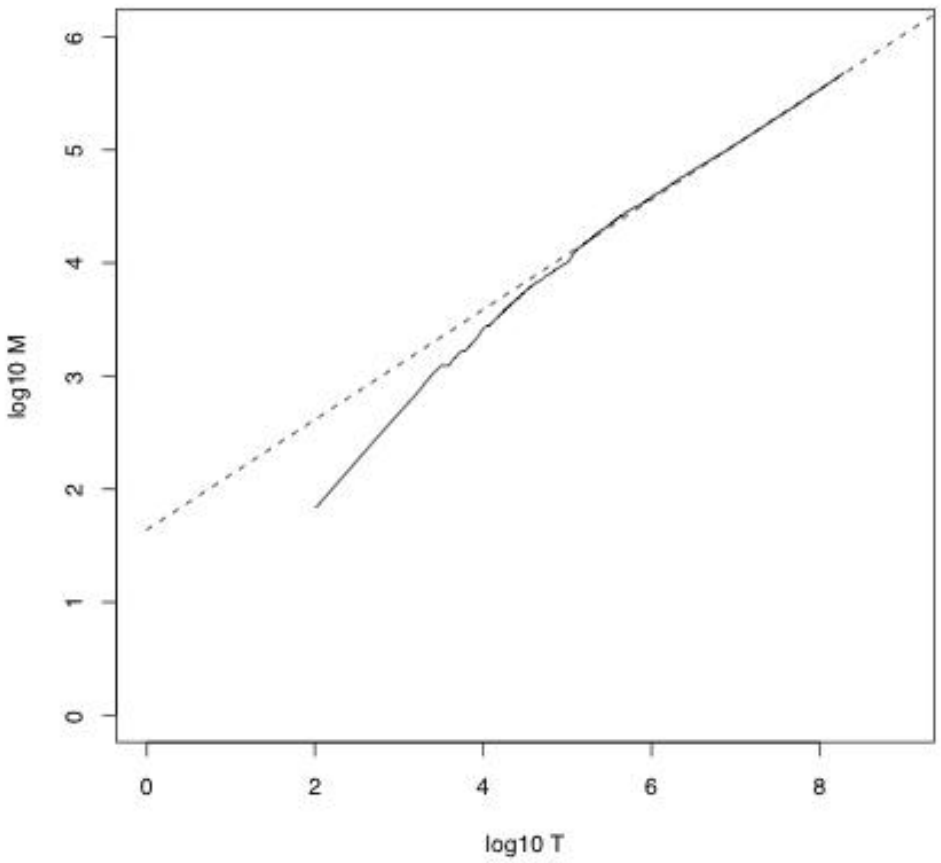

- 实线：真实分布；虚线：拟合分布
- 词汇表大小M 是文档集规模T的一个函数
- 图中通过最小二乘法拟合出的直线方程为：

$$\log_{10} M = 0.49 * \log_{10} T + 1.64$$

- 于是有：
- $M = 10^{1.64} T^{0.49}$
- $k = 10^{1.64} \approx 44$
- $b = 0.49$

拟合 vs. 真实

- 例子: 对于前1,000,020个词条， 根据Heaps定律预计将有38,323个词项:

$$44 \times 1{,}000{,}020^{0.49} \approx 38{,}323$$

- 实际的词项数目为38,365，和预测值非常接近
- 经验上的观察结果表明，一般情况下拟合度还是非常高的

课堂练习

1. 在容许拼写错误或者对拼写错误自动纠错的情况下，Heaps定律的效果如何？
2. 计算词汇表大小 M
   - 观察一个网页集合，你会发现在前10000个词条中有3000个不同的词项，在前1000000个词条中有30000个不同的词项
   - 假定某搜索引擎索引了总共20,000,000,000 (2×10^{10})个网页, 平均每个网页包含200个词条
   - 那么按照Heaps定律，被索引的文档集的词汇表大小是多少？

第二个问题：词项的分布如何？Zipf定律

- Heaps定律告诉我们随着文档集规模的增长词项的增长情况
- 但是我们还需要知道在文档集中有多少高频词项 vs. 低频词项。
- 在自然语言中，有一些极高频词项，有大量极低频的罕见词项

Zipf定律

- Zipf定律: 第*i*常见的词项的频率cf_i和1/*i* 成正比
- $\mathrm{cf}_i \propto \frac{1}{i}$
- cf_i 是语料中词项频率(collection frequency): 词项t_i在所有文档中出现的次数(不是出现该词项的文档数目df).
- 于是，如果最常见的词项(*the*)出现cf_1 次，那么第二常见的词项 (*of*)出现次数 $\mathrm{cf}_2 = \frac{1}{2}\mathrm{cf}_1 \quad \ldots$
- . . . 第三常见的词项 (*and*) 出现次数为 $\mathrm{cf}_3 = \frac{1}{3}\mathrm{cf}_1$
- 另一种表示方式: $\mathrm{cf}_i = c*i^k$ 或 $\log \mathrm{cf}_i = \log c + k \log i \quad (k = -1)$
- 幂定律(power law)的一个实例

Reuters RCV1上Zipf定律的体现

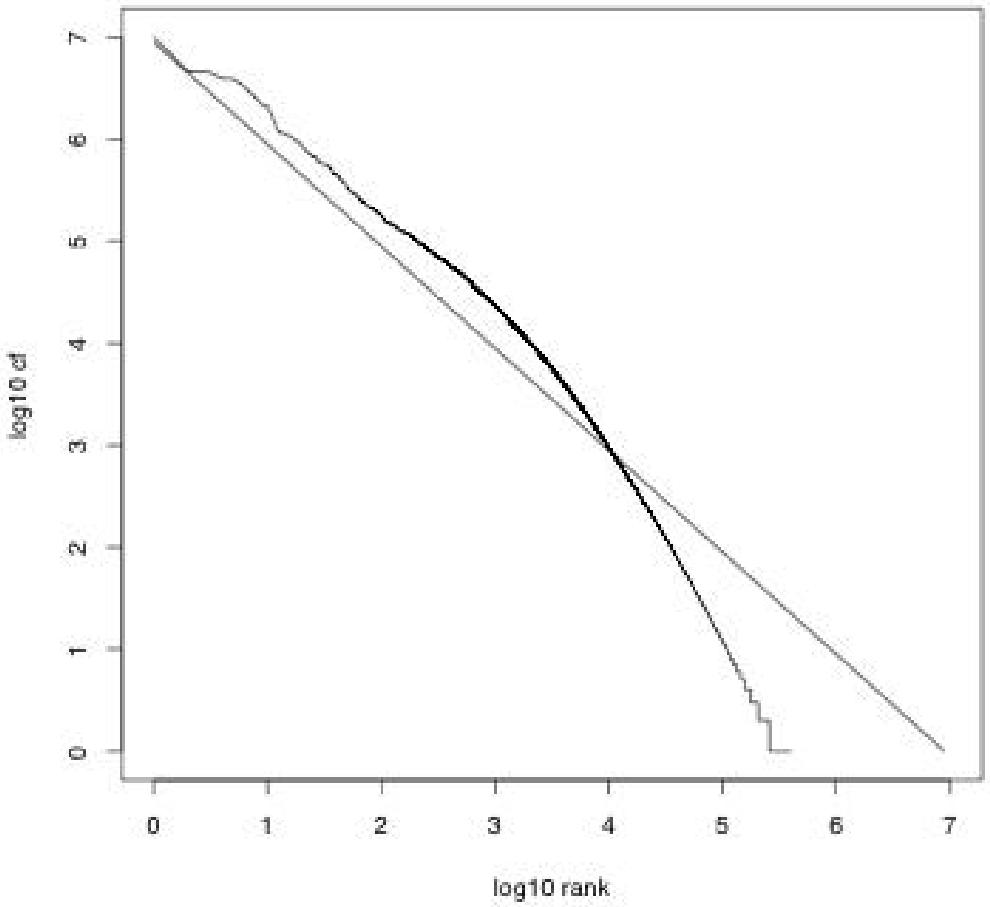

拟合度不是非常高，但是最重要的是如下关键性发现：高频词项很少，低频罕见词项很多

提纲

词典压缩

- 一般而言，相对于倒排记录表，词典所占空间较小
- 但是我们想将词典放入内存
- 另外，满足一些特定领域特定应用的需要，如手机、机载计算机上的应用或要求快速启动等需求
- 因此，压缩词典相当重要

回顾: 定长数组方式下的词典存储

- 每个词项需要20+4+4=28个字节
  - 对于RCV1，~400,000 terms; 28 bytes/term = 11.2 MB.
- 词项查找：典型的二叉树搜索

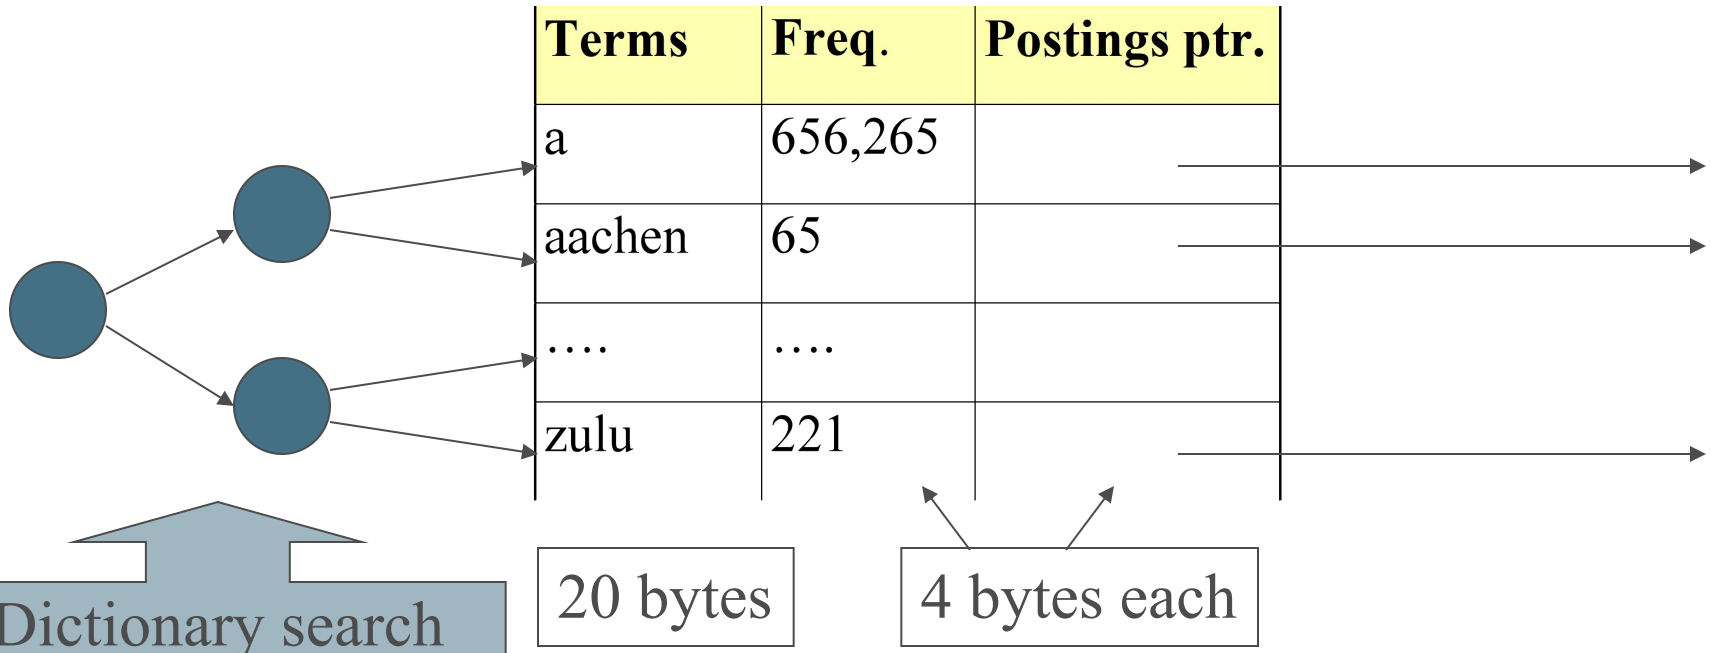

定长方式的不足

- 大量存储空间被浪费
  - 即使是长度为1的词项，我们也分配20个字节
- 不能处理长度大于20字节的词项，如HYDROCHLOROFLUOROCARBONS 和 SUPERCALIFRAGILISTICEXPIALIDOCIOUS
- 而英语中每个词项的平均长度为8个字符
- 能否对每个词项平均只使用8个字节来存储?

将整部词典看成单一字符串(Dictionary as a string)

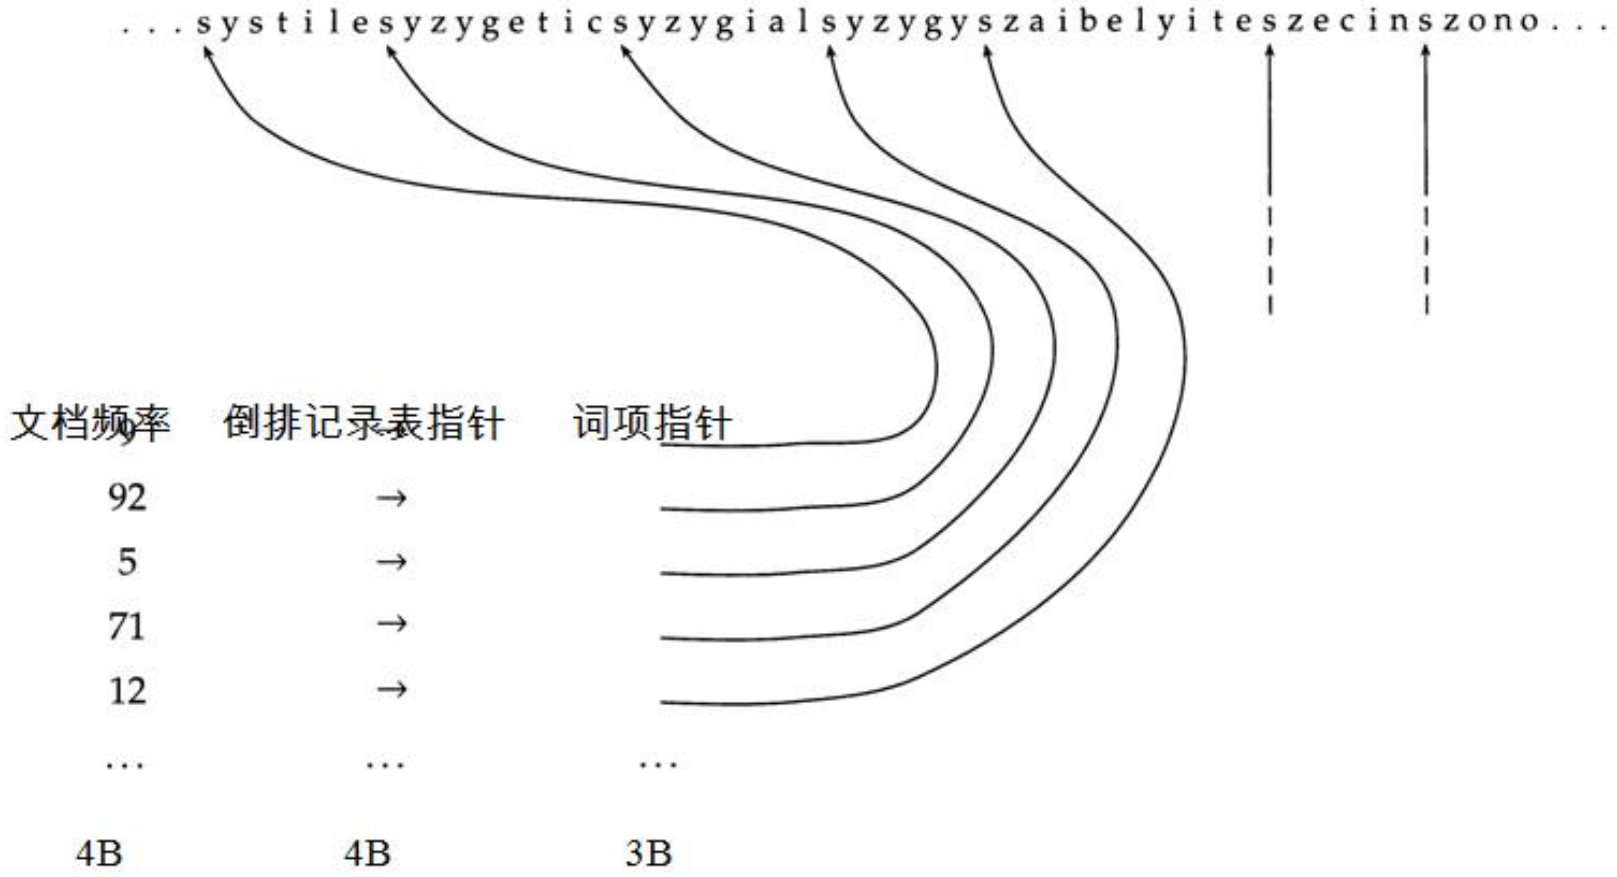

单一字符串方式下的空间消耗

- 每个词项的词项频率需要4个字节
- 每个词项指向倒排记录表的指针需要4个字节
- 每个词项平均需要8个字节
- 指向字符串的指针需要3个字节 (8*400000个位置需要 $\log_2(8 * 400000) < 24$ 位来表示)
- 空间消耗: $400{,}000 \times (4 + 4 + 3 + 8) = 7.6\text{MB}$ (而定长数组方式需要11.2MB)

单一字符串方式下按块存储

按块存储下的空间消耗

- 如果不按块存储，则每4个词项指针将占据空间4 × 3=12B
- 现在按块存储，假设块大小k=4，此时每4个词项只需要保留1个词项指针，但是同时需要增加4个字节来表示每个词项的长度，此时每4个词项需要3+4=7B
- 因此，每4个词项将节省12-7=5B
- 于是，整个词典空间将节省400,000/4*5B=0.5MB
- 最终的词典空间将从7.6MB压缩至7.1MB

不采用块存储方式下的词项查找

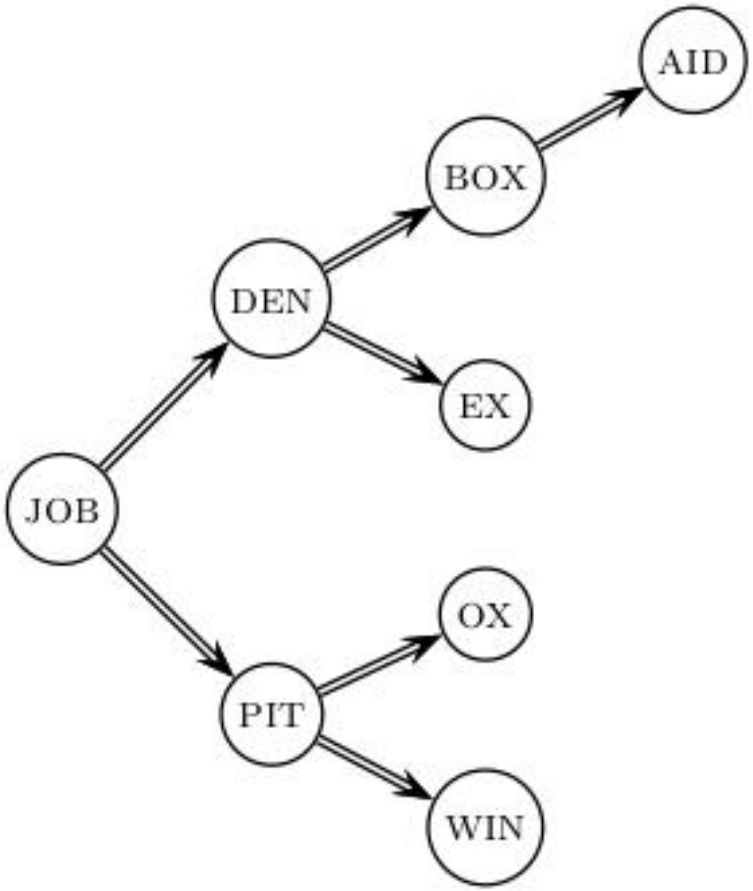

典型的二叉查找

采用块存储方式下的词项查找: 稍慢

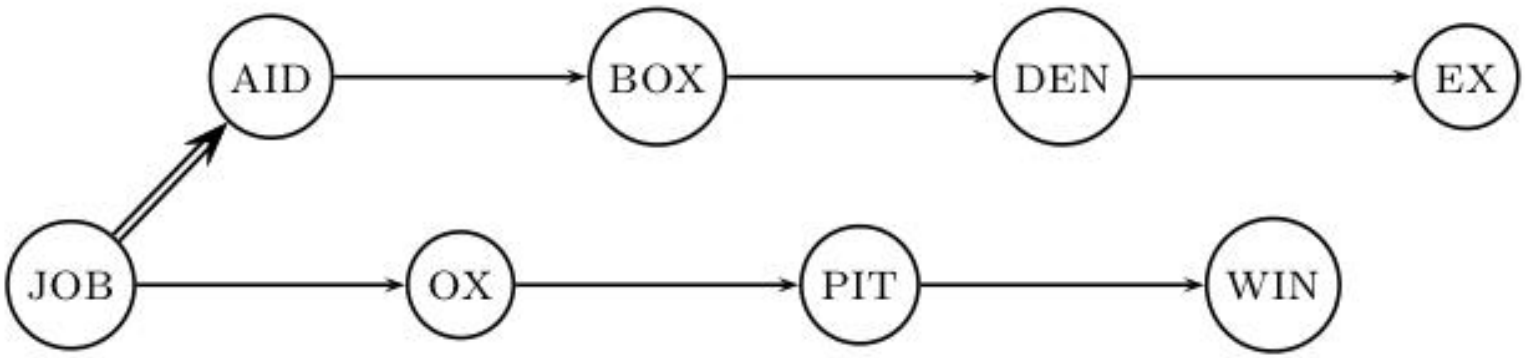

因此块不能太大，否则影响搜索效率

前端编码(Front coding)

- 每个块当中 (k = 4)，会有公共前缀 . . .
- 8automata8automate9automatic10automation
- ⇓
- . . . 可以采用前端编码方式继续压缩
- 8automat* a1◊ e2◊ ic3◊ ion

- 上面前端编码中，第一个数字8表示第一个词项长度，后面的数字1、2、3分别表示（除公共前缀外）词项剩余部分长度

Reuters RCV1词典压缩情况总表

数据结构	压缩后的空间大小（单位：MB）
词典，定长数组	11.2
词典，长字符串+词项指针	7.6
词典，按块存储，k=4	7.1
词典，按块存储+前端编码	5.9

课堂练习

- 哪些前缀应该用于前端编码？需要在哪些方面有所权衡？
  - 输入: 词项列表，即词汇表
  - 输出: 用于前端编码的前缀列表

提纲

1. 上一讲回顾
2. 压缩
3. 词项统计量
4. 词典压缩
5. 倒排记录表压缩

倒排记录表压缩

- 倒排记录表空间远大于词典，至少10倍以上
- 压缩关键：对每条倒排记录进行压缩
- 目前每条倒排记录表中存放的是docID.
- 对于Reuters RCV1(800,000篇文档), 当每个docID可以采用4字节（即32位）整数来表示
- 当然，我们也可以采用$\log_2 800{,}000 \approx 19.6 < 20$ 位来表示每个docID.
- 我们的压缩目标是： 压缩后每个docID用到的位数远小于20比特

倒排记录的两个极端情况

- 类似 ***arachnocentric*** 这样的词仅在百万分之一的文档中出现，我们使用 $\log_2 1M \approx 20$ bits 进行存储

- 而类似 ***the*** 这样的高频词几乎在所有文档中出现，因此使用 20 bits/posting ≈ 2MB 存储的代价昂贵.
  - 这种情况更适合使用 0/1 位向量(bitmap vector)(≈100K)

关键思想: 存储docID间隔而不是docID本身

- 每个倒排记录表中的docID是从低到高排序
  - 例子: COMPUTER: 283154, 283159, 283202, . . .
- 存储间隔能够降低开销：283159-283154=5, 283202-283154=43
- 于是可以顺序存储间隔(第一个不是间隔) : COMPUTER: 283154, 5, 43, . . .
- 高频词项的间隔较小
- 因此，可以对这些间隔采用小于20比特的存储方式

对间隔编码

	编码对象	倒排记录表					
the	文档ID	…	283 042	283 043	283 044	283 045	…
	文档ID间距			1	1	1	…
computer	文档ID	…	283 047	283 154	283 159	283 202	…
	文档ID间距			107	5	43	…
arachnocentric	文档ID	252 000	500 100				
	文档ID间距	252 000	248 100				

变长编码

- 目标:
  - 对于 ARACHNOCENTRIC 及其他罕见词项, 对每个间隔仍然使用20比特 (bit位)
  - 对于THE及其他高频词项，每个间隔仅仅使用很少的比特位来编码
- 为了实现上述目标，需要设计一个变长编码(variable length encoding)
- 可变长编码对于小间隔采用短编码而对于长间隔采用长编码

可变字节(VB)码

- 被很多商用/研究系统所采用
- 变长编码及对齐敏感性(指匹配时按字节对齐还是按照位对齐)的简单且不错的混合产物
- 设定一个专用位 (高位) *c*作为延续位(continuation bit)
- 如果间隔表示少于7比特，那么*c* 置 1，将间隔编入一个字节的后7位中
- 否则：将高7位放入当前字节中，并将*c* 置 0，剩下的位数采用同样的方法进行处理，最后一个字节的*c*置1（表示结束）
  - 从高到低编码

VB 编码的例子

文档ID	824	829	215 406
间距		5	214 577
VB编码	00000110 10111000	10000101	00001101 00001100 10110001

VB 编码算法

```
VBENCODENUMBER(n)
1  bytes ← ⟨⟩
2  while true
3  do PREPEND(bytes, n mod 128)
4     if n < 128
5        then BREAK
6     n ← n div 128
7  bytes[LENGTH(bytes)] += 128
8  return bytes
```

```
VBENCODE(numbers)
1  bytestream ← ⟨⟩
2  for each n ∈ numbers
3  do bytes ← VBENCODENUMBER(n)
4     bytestream ← EXTEND(bytestream, bytes)
5  return bytestream
```

130 mod 128 = 2 --> bytes 数组
130 div 128 = 1, prepend 到 bytes数组

于是循环结束有 bytes=[2,1]
算法最后一步，是在bytes[length(bytes)]上加128，即延续位置1

VB编码的解码算法

```
VBDecode(bytestream)
 1  numbers ← ⟨⟩
 2  n ← 0
 3  for i ← 1 to Length(bytestream)
 4  do if bytestream[i] < 128
 5        then n ← 128 × n + bytestream[i]
 6        else n ← 128 × n + (bytestream[i] − 128)
 7             Append(numbers, n)
 8             n ← 0
 9  return numbers
```

当延续位为1，bytestream[i]>128，因此 if bytestream[i]<128 判断的是数字之间界线（即对齐）

其它编码

- 除字节外，还可以采用不同的对齐单位：比如32位(word)、16位及4位(nibble)等等
- 如果有很多很小的间隔，那么采用可变字节码会浪费很多空间，而此时采用4位为单位将会节省空间
- 最近一些工作采用了32位的方式 - 参考讲义末尾的参考材料

γ编码

- 另外一种变长编码是基于位的编码
- γ 编码是其中最出名的一种
- 首先，在介绍γ编码之前先介绍一元码(unary code)
- 一元码：
  - 将 n 表示成 n 个1和最后一个0
  - 比如： 3的一元码是 1110
  - 40的一元码是
    1111111111111111111111111111111111111110
  - 70的一元码是：

1111111111111111111111111111111111111111111111111111111111111110

γ编码

- 将G (Gap, 间隔) 表示成长度(length)和偏移(offset)两部分
- 偏移对应G的二进制编码，只不过将首部的1去掉
- 例如 13 → 1101 → 101 = 偏移
- 长度部分给出的是偏移的位数
- 比如G=13 (偏移为 101), 长度部分位数为 3
- 长度部分采用一元编码: 1110.
- 于是G的γ编码就是将长度部分和偏移部分两者联接起来得到的结果。

γ编码的例子

数　字	一元编码	长　度	偏　移	γ 编　码
0	0			
1	10	0		0
2	110	10	0	10,0
3	1110	10	1	10,1
4	11110	110	00	110,00
9	1111111110	1110	001	1110,001
13		1110	101	1110,101
24		11110	1000	11110,1000
511		111111110	11111111	111111110,11111111
1025		11111111110	0000000001	11111111110 ,0000000001

课堂练习

- 计算130的可变字节码
- 计算130的γ编码

130二进制表示：10000010

偏移: 0000010 长度部分: 11111110

最终编码： 11111110 0000010

VB编码：00000001 10000010

γ编码的长度

- 偏移部分是 ⌊ log2 G⌋ 比特位
- 长度部分需要 ⌊ log2 G⌋ + 1 比特位
- 因此，全部编码需要2⌊ log2 G⌋ + 1比特位
- γ 编码的长度均是奇数
- γ 编码在最优编码长度的2倍左右
  - 假定间隔G的出现频率正比于log2 G—实际中并非如此)
  - (assuming the frequency of a gap G is proportional to log2 G – not really true)

γ编码的性质

- γ编码是前缀无关的，也就是说一个合法的γ 编码不会是任何一个其他的合法γ编码的前缀，也保证了解码的唯一性。
- 编码在最优编码的2或3倍之内
  - 上述结果并不依赖于间隔的分布！
- 因此， γ编码适用于任何分布，也就说γ 编码是通用性(universal)编码
- γ编码是无参数编码，不需要通过拟合得到参数

γ编码的对齐问题

- 机器通常有字边界 – 8, 16, 32 位
- 按照位进行压缩或其他处理可能会较慢
- 可变字节码通常按字边界对齐，因此可能效率更高
- 除去效率高之外，可变字节码虽然额外增加了一点点开销，但是在概念上也要简单很多
- 因此在商用系统中VB编码更常见

Reuters RCV1索引压缩总表

数据结构	压缩后的空间大小（单位：MB）
词典，定长数组	11.2
词典，长字符串+词项指针	7.6
词典，按块存储，k=4	7.1
词典，按块存储+前端编码	5.9
文档集（文本、XML标签等）	3 600.0
文档集（文本）	960.0
词项关联矩阵	40 000.0
倒排记录表，未压缩（32位字）	400.0
倒排记录表，未压缩（20位）	250.0
倒排记录表，可变字节码	116.0
倒排记录表，γ编码	101.0

Group Variable Integer code（组变长整数编码）

- Google 在2000年左右使用的算法
  - Jeff Dean, keynote at WSDM 2009 and presentations at CS276
- 按块存储。每块大小为5-17个字节，存放4个整数编码
- 每块首字节: 4个2位的二进制长度

  $\boxed{L_1}\boxed{L_2}\boxed{L_3}\boxed{L_4}$, $L_j \in \{1,2,3,4\}$
- 接下来, 使用 L1+L2+L3+L4 bytes (between 4–16) 存放4个整数
  - 每个整数占用 8/16/24/32 位，取决于整数的实际大小. 可存储的最大间隔约为 ~4 billion
- 据称比VB编码快两倍
  - 间隔解码更简单 – 这是因为没有位masking，无延续位
  - 首字节可使用查找表(lookup table)或switch解码

Simple-9 [Anh & Moffat, 2004]

怎样在32位中存放多个数字，How can we store several numbers in 32 bits with a format selector?

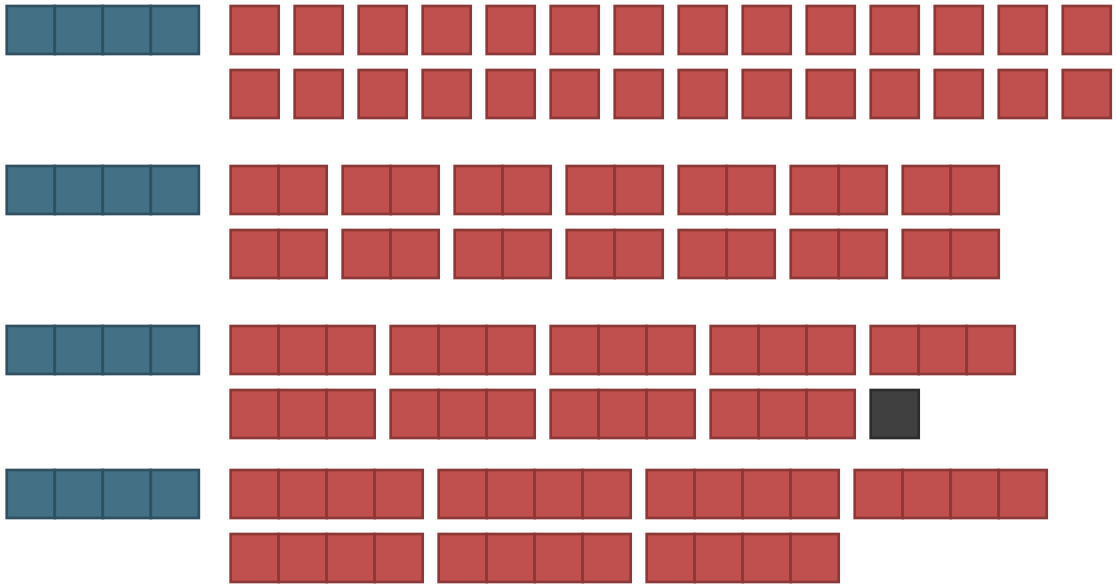

Simple9 Encoding Scheme [Anh & Moffat, 2004]

- 编码块: 4 字节(32 位), 通常一个word的占用空间
- “最显著点”(most significant nibble, 即前4 位) 概括了剩余28位的结构:
  - 0: 1个 28位数字
  - 1: 2个 14位 数字
  - 2: 3个 9位 数字 (1个空位)
  - 3: 4个 7位 数字
  - 4: 5个 5位 数字 (3个空位)
  - 5: 7个 4位 数字
  - 6: 9个 3位 数字 (1个空位)
  - 7: 14个 2位 数字
  - 8: 28个 1位 数字

Layout (4 bits)	n numbers of b bits each n * b ≤ 28

每块4字节，前4位标识块内结构，剩余28位存储若干个数字，每个数字占用相同的位数

最大可存储2^28

- Simple16 是Simple9的改进：多出了 5 个非平均结构配置
- 解码效率高
- 可扩展性强 – 例如可以扩展到64位编码

总结

- 现在我们可以构建一个空间上非常节省的支持高效布尔检索的索引
- 大小仅为文档集中文本量的10-15%
- 然而，这里我们没有考虑词项的出现位置和频率信息
- 因此，实际当中并不能达到如此高的压缩比

参考资料

- 《信息检索导论》第5章
- http://ifnlp.org/ir
  - 有关字对齐二元编码的原文Anh and Moffat (2005); 及 Anh and Moffat (2006a)
  - 有关可变字节码的原文Scholer, Williams, Yiannis and Zobel (2002)
  - 更多的有关压缩 (包括位置和频率信息的压缩)的细节参考 Zobel and Moffat (2006)